Analisi Comparativa globale tra Mortalità Neonatale ed Infantile: anlisi statistica e temporale

Giuseppe Prudente
Dipartimento di Ingegneria Informatica
Università degli Studi di Perugia
Perugia, Italia
giuseppe.prudente@studenti.unipg.it

***Abstract*—Nel presente report è stata condotta un'analisi comparativa della mortalità infantile e della mortalità neonatale a livello globale, con riferimento a un arco temporale superiore a vent'anni (2000–2021). L'indagine si è basata su dataset contenenti osservazioni relative ai diversi Paesi del mondo, aggregati in sei macro-regioni principali: Eastern Mediterranean, Europe, Africa, Americas, Western Pacific e South-East Asia. Per ciascun dataset, le informazioni disponibili comprendono il numero di decessi attribuibili a una specifica causa, l'anno di rilevazione e la localizzazione geografica di riferimento. Le analisi esplorative, statistiche e temporali sono state realizzate mediante il linguaggio R, con il supporto per la produzione di alcune immagini di Python con la rispettiva libreria MatplotLib. Sono state calcolate statistiche descrittive per ciascun dataset e sono state condotte analisi comparative di natura geospaziale e temporale su entrambi i campioni considerati, al fine di evidenziarne analogie, differenze e principali tendenze evolutive nel periodo oggetto di studio.**

***Index Terms*—Mortalità infantile, Mortalità Neonatale, Globale, Analisi Statistica, Analisi Temporale, Analisi di confronto, Analisi Geospaziale, R**

I. Introduzione

Il presente progetto, sviluppato in occasione dell'esame finale del corso di *Data Science for Health Systems*, si propone di realizzare un'analisi approfondita dei singoli campioni oggetto di studio(mortalità neonatale [1] e mortalità infantile [2]) ma anche un'analisi comparativa tra gli stessi, al fine di individuare e interpretare le principali differenze emergenti, sia da un punto di vista geospaziale che temporale. Gli strumenti di analisi esplorativa e di analisi statistica sono stati selezionati in modo differenziato a seconda che l'indagine riguardasse un singolo campione o un confronto comparativo tra i due dataset, così da garantire coerenza metodologica e adeguatezza rispetto agli obiettivi specifici di ciascuna fase analitica.

II. Materiali e Metodi

A. Dataset

Sono stati analizzati tre dataset distinti, denominati rispettivamente: *Child deaths in neonates, neonatal deaths (0 to 27 days), number* [1] , *Child deaths, infant deaths (between birth and 11 months)* [2] e *Child deaths in children aged less than 5 years, by cause, number* [3]. I primi due dataset raccolgono osservazioni in un intervallo temporale compreso tra il 1955 e il 2023, con riferimento ai Paesi appartenenti alle sei macro-regioni in cui è convenzionalmente suddiviso il globo. Le principali variabili considerate includono: il nome dello Stato in cui è stata effettuata la rilevazione (**LOCATION**), la macro-regione di appartenenza (**PARENT LOCATION**), l'anno di osservazione (**PERIOD**) e il numero di decessi registrati nello specifico Paese e anno (**VALUE**). Il dataset *Child deaths in children aged less than 5 years, by cause, number* contiene invece informazioni relative alle cause di morte per ciascuno Stato in un arco temporale di 22 anni (2000–2021). Oltre alle variabili **PARENT LOCATION**, **LOCATION** e **PERIOD**, esso include la causa principale di morte (**CAUSE**) e il corrispondente codice ICD-10 [8] (**CAUSE CODE**) [4]. Si precisa che da quest'ultimo dataset sono stati derivati due sottoinsiemi distinti, sui quali sono state successivamente condotte le analisi, adottando come criterio di suddivisione la fascia di età dei soggetti considerati (0–27 giorni e 0–11 mesi). Tutti i dati utilizzati sono stati estratti dal portale ufficiale della **World Health Organization**, che raccoglie e mette a disposizione informazioni di natura temporale e geospaziale relative alla mortalità neonatale e infantile a livello globale. [5]

B. Dataset

Tutte le analisi sono state effettuate in **R**. I principali pacchetti utilizzati includono *dplyr, ggplot2, gridExtra, tidyverse* per le analisi statistiche, inoltre per fini esclusivamente di presentazione di alcuni grafici si è optato per l'utilizzo del linguaggio di programmazione Pyhton e della libreria *Matplotlib*.

III. Analisi Esplorativa

A. Statistiche Descrittive

In una fase preliminare dell'analisi, sono state calcolate le principali statistiche descrittive (media, mediana, deviazione standard, valore minimo e valore massimo) relative ai decessi neonatali e infantili. Tali misure sono state stimate sia a livello

globale (Tab. I) sia con riferimento alle singole macro-regioni considerate, coprendo l'intero arco temporale oggetto di studio (2000–2021), al fine di fornire un quadro sintetico e comparativo della distribuzione dei fenomeni analizzati. Nell'ambito dell'analisi esplorativa sono state realizzate diverse rappresentazioni grafiche con l'obiettivo di esaminare la distribuzione e la variabilità delle cause di morte nei due gruppi considerati, nonché di individuare eventuali differenze strutturali tra le fasce di età analizzate. In primo luogo, sono stati elaborati due diagrammi a torta (Fig. 1) , che illustrano la quota percentuale di ciascuna causa sul totale dei decessi per ciascun gruppo. Tale rappresentazione consente di evidenziare come la composizione relativa delle cause vari al variare dell'età, mettendo in luce eventuali differenze nelle priorità sanitarie tra il periodo neonatale e quello successivo. Successivamente, sono stati prodotti due grafici a barre orizzontali (Fig. 2 , Fig. 3) in cui è riportato il numero totale di decessi per causa, aggregato su tutti i Paesi e sull'intero intervallo temporale considerato. Questa visualizzazione permette di identificare in modo immediato le cause dominanti nel periodo analizzato, fornendo un confronto diretto tra i due gruppi di età. Per approfondire la distribuzione statistica dei decessi, sono stati inoltre costruiti box plot (Fig. 4, Fig. 5) relativi al numero di decessi per ciascuna causa nell'arco temporale 2000–2021. Tali grafici evidenziano la mediana, la dispersione dei dati e la presenza di eventuali valori anomali (outlier), consentendo di analizzare la variabilità tra Paesi diversi rispetto alla medesima causa di morte. Infine, sono stati realizzati due bar chart dei primi dieci Paesi per mortalità totale (Fig. 6, Fig: 7) ottenuta aggregando i decessi su tutte le cause e su tutti gli anni considerati. Questa analisi risulta particolarmente utile per individuare i contesti caratterizzati da maggiore criticità in termini assoluti.

TABLE I
STATISTICHE DESCRITTIVE GLOBALI DEI DECESSI NEONATALI E INFANTILI (2000–2021)

Dataset	Mean	Median	Std Dev	Min	Max
Deaths < 1 Month	1109.64	2.6	9246.31	0.0	471918.3
Deaths < 1 Year	1346.22	9.2	8946.44	0.0	310274.2

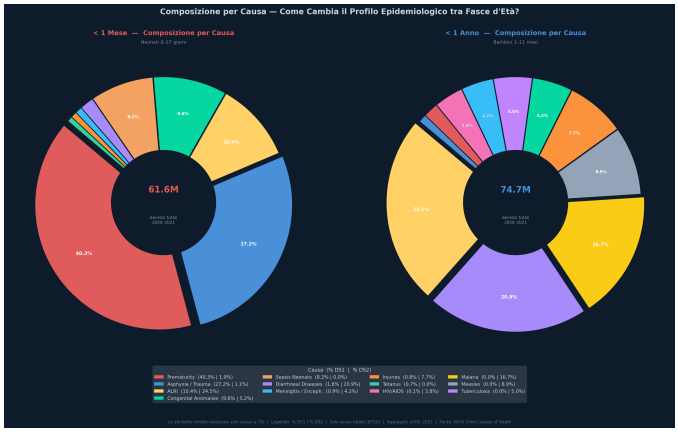

Fig. 1. Confronto della composizione per causa

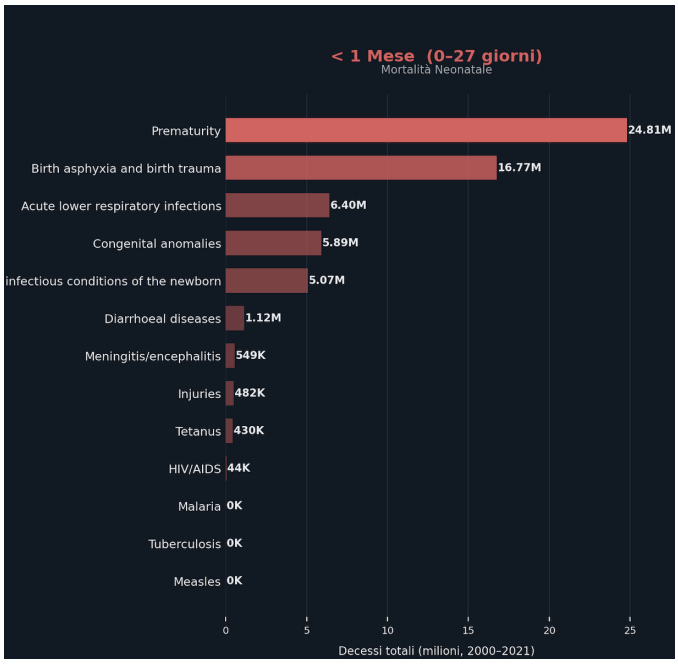

Fig. 2. Distribuzione delle cause di morte 0-27 giorni

B. *Visualizzazione spaziale e temporale*

Nell'ambito dell'analisi spaziale, è stata considerata una rappresentazione cartografica (Fig. 8) tratta dal portale ufficiale della World Health Organization [6]. Tale visualizzazione riporta il tasso di mortalità neonatale, espresso come numero di decessi neonatali ogni 1.000 nati vivi, questo permette un'analisi totalmente decorrelata dalla grandezza della popolazione del paese preso in esame. La piattaforma consente inoltre una consultazione interattiva dei dati, permettendo il filtraggio per Paese e per anno, offrendo così un quadro dinamico delle differenze geografiche e temporali del fenomeno. Successivamente è stata condotta la prima indagine temporale che riguarda l'andamento globale dei decessi nel periodo 2000–2021. È stato pertanto costruito un line chart (Fig. 9) raffigurante il totale mondiale dei decessi per anno. Il grafico mostra separatamente le due serie (neonatale e post-neonatale), consentendo un confronto diretto del ritmo di riduzione tra le due fasce di età. Dall'analisi emergono tre evidenze quantitative di rilievo: il primo dataset (0-27 giorni) registra una diminuzione complessiva di circa il 42% tra il 2000 e il 2021, mentre il secondo dataset (1-11 mesi) evidenzia una riduzione più marcata, pari a circa il 53%. La seconda analisi temporale ha riguardato l'evoluzione negli anni del rapporto tra mortalità neonatale e mortalità complessiva infantile, rappresentata mediante un line chart (Fig. 10) del rapporto globale *Morti Neonatali/Morti Totali* per ciascun anno. Tale indicatore consente di rispondere al quesito se la quota di mortalità neonatale sia aumentata o diminuita rispetto a quella post-neonatale nel periodo considerato. Un eventuale

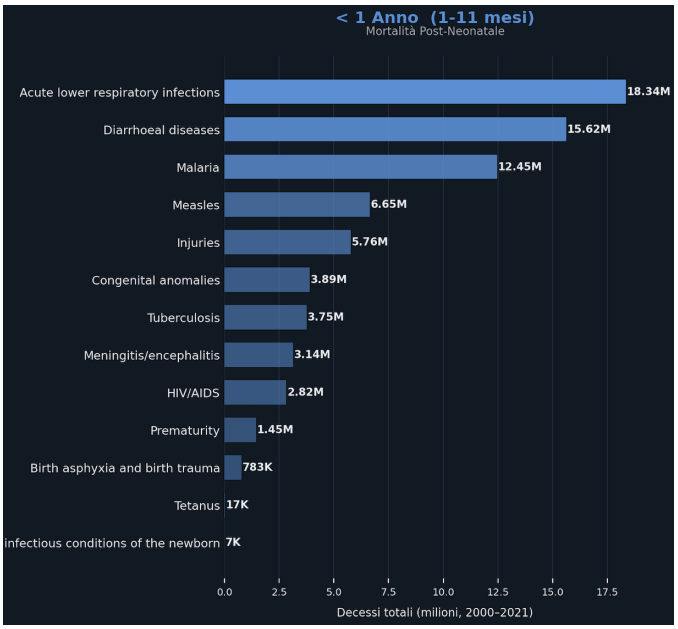

Fig. 3. Distribuzione delle cause di morte 0-11 mesi

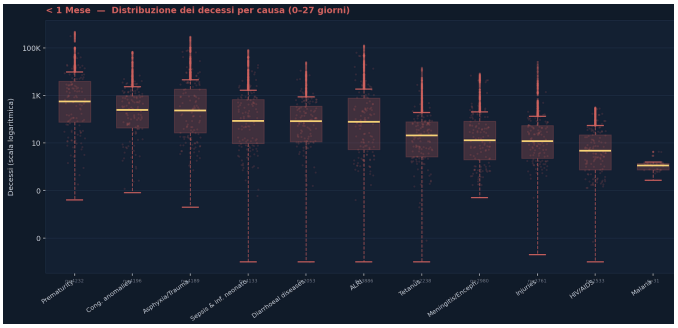

Fig. 4. BoxPlot: Statistiche descrittive per causa (0-27 giorni)

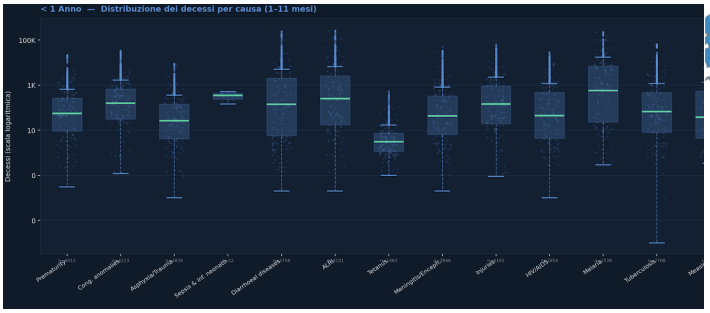

Fig. 5. BoxPlot: Statistiche descrittive per causa (0-11 mesi)

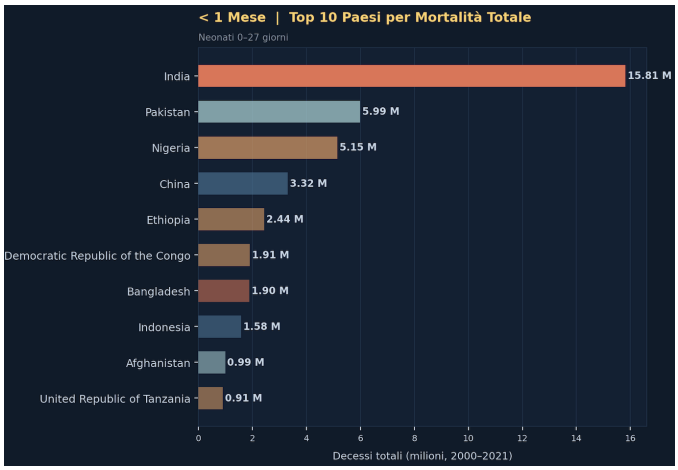

Fig. 6. Primi dieci Paesi per mortalità totale (0-27 giorni)

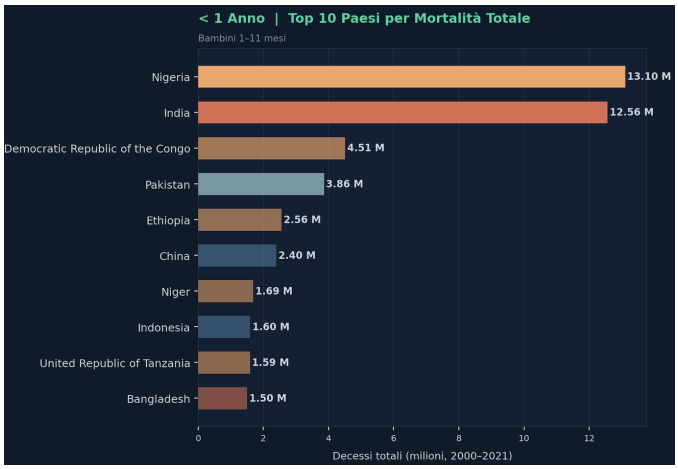

Fig. 7. Primi dieci Paesi per mortalità totale (0-11 mesi)

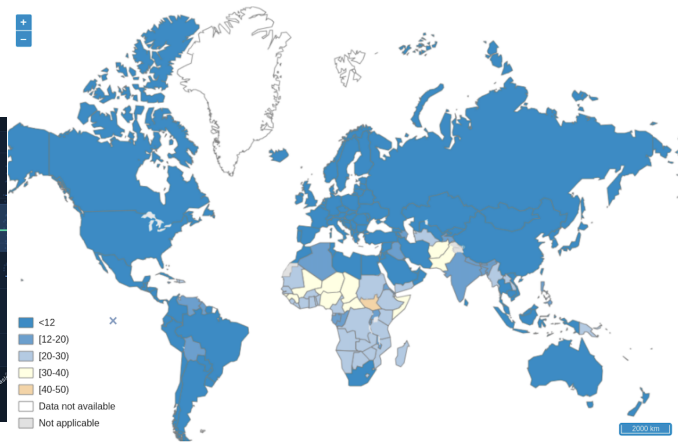

Fig. 8. Rate di Mortalità neonatale 0-27 giorni (per 1000 live births

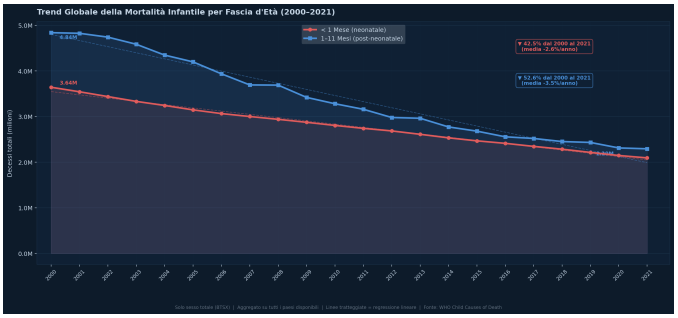

Fig. 9. Trend globale: andamento nel tempo dei morti neonatali ed infantili (2000-2021)

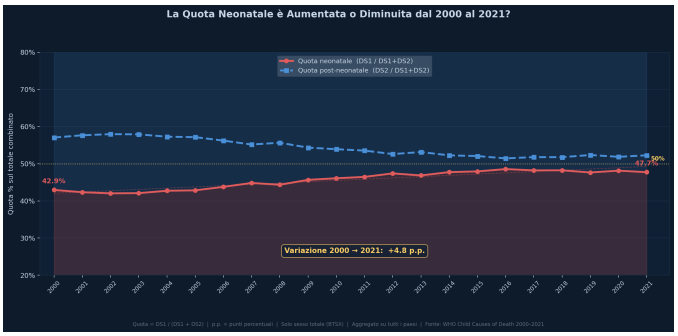

Fig. 10. Evoluzione del rapporto tra mortalità neonatale e mortalità complessiva infantile

incremento della quota indica che la mortalità post-neonatale sta diminuendo più rapidamente rispetto a quella neonatale, determinando una progressiva concentrazione del fenomeno nei primissimi giorni di vita.

IV. Analisi Statistica

In prima istanza è stata effettuata un'analisi preliminare della distribuzione dei dati raccolti. La verifica dell'assunzione di normalità è stata condotta separatamente per ciascuna delle sei regioni dell'Organizzazione Mondiale della Sanità (OMS), al fine di valutare l'appropriatezza dell'impiego di test statistici di natura parametrica. Per esigenze di sintesi e di gestione dello spazio all'interno del report, viene presentato esclusivamente il grafico relativo alla curva del test di Kolmogorov-Smirnov per la Regione Europea, mentre i risultati completi per le restanti regioni, privi di rappresentazione grafica, sono riportati in forma tabellare. (Tab. II).

TABLE II
Risultati del test di Kolmogorov–Smirnov per regione OMS

Regione OMS	**n**	**D**	D_{crit}	**Normalità**
Eastern Mediterranean	6006	0.418	0.018	False
Europe	15158	0.414	0.011	False
Africa	13442	0.389	0.012	False
Americas	10010	0.401	0.014	False
Western Pacific	8008	0.436	0.015	False
South-East Asia	2860	0.425	0.025	False

A. Test di Normalità

E' stata condotta una verifica dell'assunzione di normalità delle distribuzioni mediante test di Kolmogorov–Smirnov [8]. L'esito di tali verifiche ,riportate in figura (Fig. 11), in considerazione della frequente deviazione dall'ipotesi di normalità e della presenza di asimmetrie e valori estremi, ha orientato la scelta di procedure non parametriche per il confronto tra gruppi. La tabella (Tab. II) riporta i risultati del test di Kolmogorov–Smirnov , ottenuti su tutte le macro-regioni OMS, includendo per ciascuna: la numerosità campionaria n, la statistica del test D e il valore critico D_{crit}.La numerosità campionaria varia in modo rilevante tra le regioni: l'Europa risulta la più numerosa (n = 15.158), mentre il Sud-Est Asiatico rappresenta la meno numerosa (n = 2.860). Tale informazione è cruciale poiché il valore critico D_{crit} dipende direttamente da n, diminuendo all'aumentare della dimensione campionaria. La statistica D è stata calcolata come la massima distanza verticale tra la funzione di distribuzione cumulativa empirica dei dati (**ECDF**) e la funzione di distribuzione cumulativa teorica di una distribuzione normale stimata utilizzando media e deviazione standard campionarie. I risultati mostrano che tutte e sei le regioni OMS rifiutano l'ipotesi nulla di normalità, con valori di D ampiamente superiori ai rispettivi valori critici. Tale evidenza fornisce una solida giustificazione metodologica per l'impiego di procedure non parametriche, in particolare del test di Kruskal–Wallis, nel confronto tra gruppi descritto nel passo successivo.

B. Test non Parametrici

Al fine di individuare le differenze specifiche tra le distribuzionni di decessi tra regioni, il test di Kruskal–Wallis [9] è stato applicato separatamente a ciascuna delle 15 combinazioni possibili di coppie tra le sei regioni. I risultati dettagliati sono riportati in Tabella III. La maggior parte delle coppie presenta p−value prossimi allo zero, indicando differenze marcate tra le distribuzioni. L'unica coppia con significatività marginale è **Americas vs Western Pacific** (H_{corr} = 4.99; p = 0.024), valore comunque inferiore alla soglia alpha = 0.05 prefissata. Questi risultati suggeriscono che le distribuzioni regionali dei decessi differiscono sistematicamente tra loro. In Fig. 12 viene riportato una heatmap rappresentante quanto osservato. E' necessario far notare che l'esecuzione di 15 test indipendenti comporta un aumento inevitanbile della probabilità complessiva di errore di I tipo (Family-Wise Error Rate).
$P(\text{almeno un F.P.}) = 1 - (1 - 0.05)^{15} = 1 - 0.95^{15} \approx 0.54\%$

Per tale ragione, l'interpretazione dei confronti a coppie richiede l'applicazione di procedure di correzione per confronti multipli (ad esempio la correzione di Bonferroni [10]), al fine di garantire un adeguato controllo dell'errore di I tipo complessivo (family-wise error rate). Tuttavia, l'approfondimento e l'applicazione sistematica di tali procedure non vengono trattati in questa report.

TABLE III
KRUSKAL-WALLIS A COPPIE — DECESSI INFANTILI < 1 MESE
($\alpha = 0.05$)

Coppia	H_{corr}	C_{ties}	p-value	Sig.
ESM vs EUR	1321.82	0.9073	0.0000e+00	✓
ESM vs AFR	215.84	0.9816	0.0000e+00	✓
ESM vs AMR	537.21	0.9354	0.0000e+00	✓
ESM vs WEP	437.49	0.9572	0.0000e+00	✓
EUR vs AFR	4437.48	0.9425	0.0000e+00	✓
EUR vs AMR	173.96	0.8824	0.0000e+00	✓
EUR vs WEP	223.40	0.8984	0.0000e+00	✓
EUR vs SEA	1187.00	0.8965	0.0000e+00	✓
AFR vs AMR	2132.06	0.9619	0.0000e+00	✓
AFR vs WEP	1838.35	0.9739	0.0000e+00	✓
AMR vs SEA	604.07	0.9299	0.0000e+00	✓
WEP vs SEA	539.83	0.9578	0.0000e+00	✓
ESM vs SEA	37.15	0.9761	2.8462e-08	✓
AFR vs SEA	19.73	0.9850	2.2356e-05	✓
AMR vs WEP	4.99	0.9233	2.4168e-02	✓

V. CLUSTERIZZAZIONE

A. *Clustering PCA con Metodo del gomito*

E' stata condotta un'analisi di clustering congiunta applicando l'algoritmo K-means alle osservazioni nazionali. Come variabili di input sono stati utilizzati i decessi normalizzati per causa, considerando simultaneamente le informazioni provenienti da entrambi i dataset (mortalità neonatale e post-neonatale). Tale impostazione consente di costruire una rappresentazione integrata del profilo di mortalità infantile, superando la distinzione rigida tra le due fasce di età e cogliendo similarità strutturali non immediatamente evidenti. La determinazione del numero ottimale di cluster (k=8) è stata effettuata in modo oggettivo mediante la cosiddetta **Elbow Technique** [11]. In particolare, è stata analizzata la curva al variare di k e individuato il punto di massima curvatura come mostrato in Fig. 13. Per finalità di visualizzazione, i risultati del clustering sono stati proiettati nello spazio bidimensionale ottenuto tramite Principal Component Analysis (PCA) [12]. Lo scatter plot risultante (Fig. 14) mostra la distribuzione dei Paesi lungo le prime due componenti principali, con evidenziazione degli otto cluster identificati e l'etichettatura dei Paesi caratterizzati da maggiore numerosità di decessi. Un risultato di particolare interesse riguarda il numero di cluster individuati: nonostante i dataset siano originariamente organizzati in sei macro-regioni geografiche, l'analisi ha evidenziato la presenza di otto gruppi distinti. Tale evidenza suggerisce che le differenze nei profili epidemiologici non si esauriscono nella suddivisione geografica convenzionale, ma riflettono comportamenti eterogenei anche tra Paesi appartenenti alla medesima macro-regione. In altri termini, l'approccio di clustering mette in luce una struttura più articolata del fenomeno, evidenziando similarità trasversali e divergenze interne che non emergono dalla sola classificazione geografica.

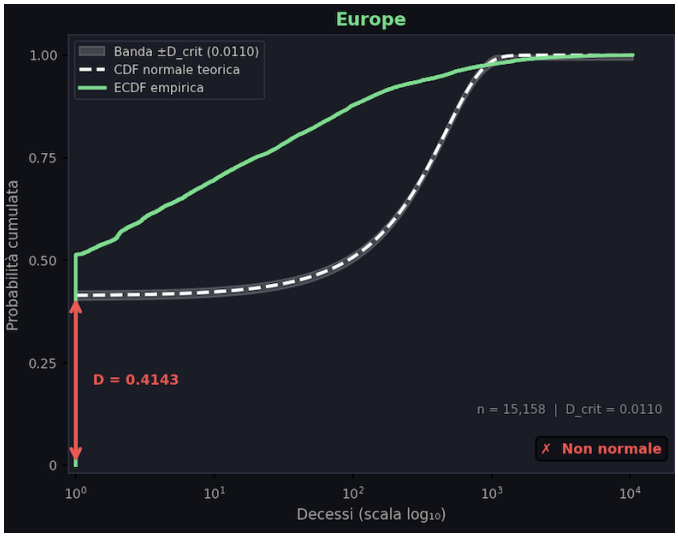

Fig. 11. Test Kolmogorov-Smirnov: CDF Empirica vs CDF Teorica

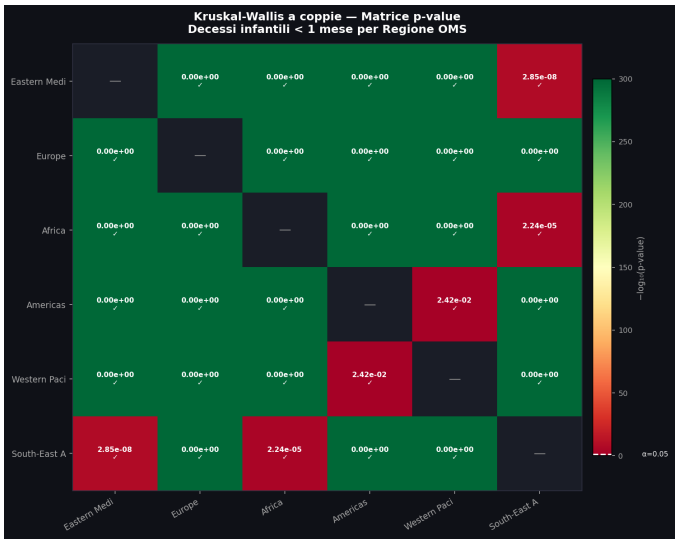

Fig. 12. Kruskal-Wallis a coppie: matrice P-Values

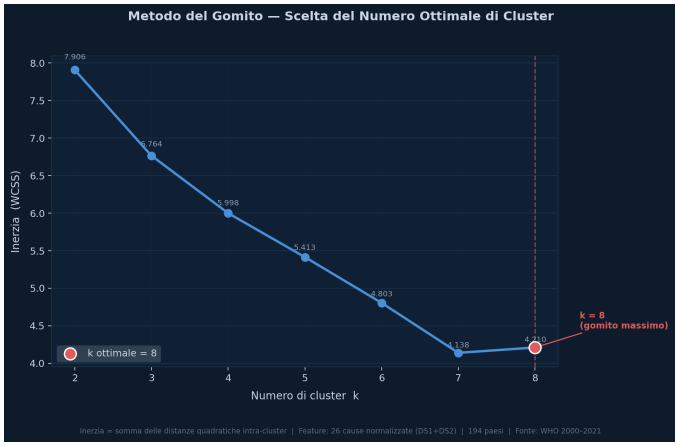

Fig. 13. Curva Gomito per la Selezione del K ottimale

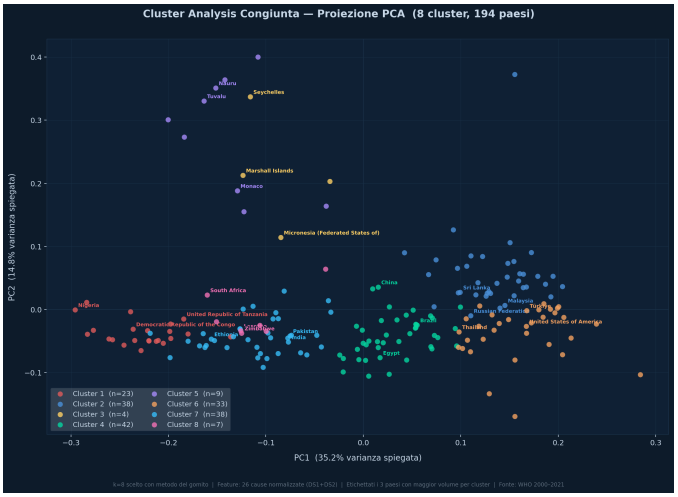

Fig. 14. Proiezione nello spazio bidimensionale tramite Principal Component Analysis (PCA)

Conclusioni

Il presente studio ha analizzato in modo comparativo la mortalità neonatale (0–27 giorni) e la mortalità infantile post-neonatale (1–11 mesi) a livello globale, integrando analisi descrittive, temporali, geospaziali e metodi statistici. I risultati evidenziano innanzitutto una marcata riduzione dei decessi in entrambe le fasce di età nel periodo 2000–2021: circa -42% per la mortalità neonatale e -53% per quella post-neonatale. Tale evidenza conferma i progressi compiuti negli ultimi due decenni nell'ambito delle politiche sanitarie internazionali, in linea con gli obiettivi delineati dall'World Health Organization [5]. Nonostante il trend decrescente, l'analisi temporale ha mostrato un progressivo rallentamento del ritmo di riduzione negli anni più recenti (2019–2021), suggerendo la possibile presenza di fattori strutturali che rendono più complesso ottenere ulteriori miglioramenti. Inoltre, l'analisi del rapporto tra mortalità neonatale e mortalità infantile totale indica una crescente concentrazione dei decessi nei primissimi giorni di vita, segnalando come la fase neonatale rappresenti oggi la componente relativamente più critica della sopravvivenza infantile.

Particolarmente rilevante è il risultato emerso dall'analisi di clustering: l'individuazione di otto cluster ottimali, a fronte delle sei macro-regioni geografiche convenzionali, dimostra che la distribuzione della mortalità infantile non può essere pienamente spiegata dalla sola appartenenza geografica. I profili epidemiologici risultano infatti più articolati, con similarità trasversali tra Paesi di regioni differenti e differenze interne alle stesse macro-aree. Questo risultato sottolinea l'importanza di adottare approcci data-driven nella definizione delle politiche sanitarie, superando classificazioni esclusivamente geografiche. In conclusione, lo studio conferma un significativo progresso globale nella riduzione della mortalità infantile, ma evidenzia al contempo la necessità di concentrare gli sforzi futuri sulla fase neonatale, oggi proporzionalmente più vulnerabile. Interventi mirati sulla salute materno-infantile, sul miglioramento dell'assistenza al parto e sulla gestione delle complicanze precoci potrebbero generare un impatto sostanziale nel percorso verso l'eliminazione delle morti prevenibili nei primi anni di vita.

References

[8] ICD-10 Version:2019: https://icd.who.int/browse10/2019/en

[1] Child deaths in neonates, neonatal deaths (0 to 27 days), number WHO dataset: https://www.who.int/data/gho/data/indicators/indicator-details/GHO/number-of-neonatal-deaths

[2] Child deaths, infant deaths (between birth and 11 months) WHO dataset: https://www.who.int/data/gho/data/indicators/indicator-details/GHO/number-of-infant-deaths

[3] Child deaths in children aged ¡5 years, by cause, number: https://www.who.int/data/gho/data/indicators/indicator-details/GHO/number-of-deaths

[4] MetaData Child deaths in children aged ¡5 years, by cause, number: https://www.who.int/data/gho/data/indicators/indicator-details/GHO/number-of-deaths

[5] SDG Target 3.2: End preventable deaths of newborns and children under 5 years of age: https://www.who.int/data/gho/data/themes/topics/sdg-target-3_2-newborn-and-child-mortality

[6] Geographical Maps of Neonatal Mortality Rate SDG Target 3.2: End preventable deaths of newborns and children under 5 years of age: https://www.who.int/data/gho/data/themes/topics/sdg-target-3_2-newborn-and-child-mortality

[7] Pareto principle: https://en.wikipedia.org/wiki/Pareto_principle

[8] Kolmogorov-Smirnov Test: https://www.itl.nist.gov/div898/handbook/prc/section2/prc212.htm

[9] Kruskal, W. H., and Wallis, W. A. (1952). Use of Ranks in One-Criterion Variance Analysis. Journal of the American Statistical Association, 47(260), 583–621. https://doi.org/10.1080/01621459.1952.10483441

[10] Bonferroni, C.E. (1936) Teoria statistica delle classi e calcolo delle probabilità, Pubblicazioni del R Istituto Superiore di Scienze Economiche e Commerciali di Firenze 8, 3-62.

[11] Thorndike RL. Who Belongs in the Family? Psychometrika. 1953;18(4):267-276. doi:10.1007/BF02289263 https://www.cambridge.org/core/journals/psychometrika/article/abs/who-belongs-in-the-family/5270D9B37A258A06C7CE7C0A528145F5

[12] Principal Component Analysis: A Natural Approach to Data Exploration. https://doi.org/10.1145/3447755